数据质量问题处理建议

整理人：赵思嘉

四类问题是什么？

1. 缺失值 (Missing Values)

数据表中某些单元格是空的（NaN、空字符串、特殊标记如“未知”）。在 App 数据中，最典型的就是 Rating 字段大量为空，代表该 App 没被评分过。

传统处理：

1. 删除：缺失率极低（<5%）且样本量大时，直接删掉这一行。容易损失信息，不推荐首选。
2. 统计插补：用均值、中位数（数值型）或众数（类别型）填补。
3. 保留标记：新增一列 is_rating_missing（0 或 1），保留“原本缺失”的事实。对于后续聚类，“没有评分”本身就是一种重要的 App 特征，绝对不要盲目填 0。

把数据统计结果传给大模型：

告诉模型哪些列缺失、缺失比例。AI 读取数据后，判断每一列适合哪种处理策略：哪些删、哪些插补、哪些做缺失标记，输出处理计划。

AI 输出 Python 代码，执行填充 / 增加标记列。

AI 写日志：记录哪多少条是缺失、采用了什么策略。

2. 重复数据 (Duplicate Data)

数据集中出现了完全一样的记录，或者主键（如 App 名称）相同但其他属性（如评论数）不同的记录。App 数据集中存在完全重复行。

传统处理：

1. 完全重复：所有字段一模一样，直接去重（保留第一条）。
2. 部分重复（同名不同属性）：如果两个 App 名字一样，但评论数不同，可能是不同版本或采集时间不同，盲目合并会丢失有效信息，应该打上标记，留待人工复核。

AI 编写 df.duplicated()检测，发现全字段重复后自动删去，并记录“去除 X 条重复记录”；发现同名不同属性时，主动预警，生成日志要求人类确认。

3. 异常值/噪声 (Outliers/Noise)

数据超出了正常的业务逻辑范围（如 Rating=19，满分明明是 5 分），或者整行数据发生了“错位”（比如一个数值跑到了文本列里）。

传统处理：

1. 业务规则优先：硬性规则如 Rating 大于 5 或小于 0，直接判定为错误（噪声）。
2. 隔离而非修改：对于错位记录，绝对不要强行用平均值去修正，因为往往一整行都错了，修一个值毫无意义。应该把这条记录隔离（标记后剔除），不参与聚类，但保留在原始数据中，方便对比实验。

AI 收到“Rating 最大值不超过 5”的提示词后，自动检测出 Rating=19，识别为错位噪声，调用 Python 工具将其隔离，并在运行记录中写入：“触发异常值检测工具，隔离 1 条错位记录”。

4. 类型/格式不一致 (Inconsistent Types/Formats)

同一个字段里混用了多种格式或单位。比如 Size 列有`19M`、`201k`、`Varies with device`（三种文本混在一起）；Installs 列带逗号和加号（`10,000+`）；Price 列带有美元符号。

传统处理：

1. 统一单位：`19M`转为`19`（MB），`201k`转为`0.201`，统一写一个解析函数。
2. 清洗字符串：`10,000+`去掉逗号和加号，转为`10000`。
3. 特殊状态特殊对待：`Varies with device`（随设备变化）**绝不能填 0**，应单独标记为`-1`或 NaN，保留其特殊语义。

AI 观察文本格式，自主写出正则表达式或转换函数（lambda 函数），执行转换，并记录日志。

Google Play Store Apps

问题类型	怎么发现	可以怎么处理	举例
1. 缺失值	用 df.isna().sum() 统计各列空值数量；检查特殊占位符（如“未知”、空字符串）。	1. 不盲目全量填充，区分缺失原因； 2. 缺失率低可删除，占比高用中位数/众数插补； 3. 增加缺失标记列，保留原始信息，方便三组对比实验（最低必要处理、固定规则、智能体）。	Rating 字段存在大量 NaN，代表该 App 未收集到用户评分，不建议直接填 0；可选择中位数插补，或保留缺失标记。
2. 重复数据	用 df.duplicated().sum() 查完全重复行；用 value_counts() 检查唯一标识 App；不能仅凭 App 名称判定重复（同名可能是不同软件），需联合多列核验。	1. 整行完全重复：保留第一条，删除其余重复样本； 2. 同名但评分、评论数等属性不同：不自动合并，标记待人工复核。	数据集存在多条所有字段完全一致的 App 记录，属采集重复，直接去重；两个 App 名字相同但评论数不同，标记留存，不自动删除。
3. 异常值/噪声（逻辑错误、错位）	业务值域校验：Rating 应在 0–5 分，筛选区间外数值；检查整行是否发生字段错位。	1. 确认为录入错位、无法可靠修复的样本做隔离标记，不强行修改； 2. 不直接全部删除，保留原始记录并记录处理日志。	某条记录 Rating=19，超出 0–5 评分上限，判定为数据错位噪声；不做自动修正，标记隔离，用于对比实验。
4. 类型/格式不一致	检查数据类型 dtypes；查看文本字段是否包含多种单位、符号；检查日期格式是否统一。	1. 统一单位：M 转 MB、k 转 KB； 2. 去除 Installs 字段的逗号、加号，转为数值； 3. “Varies with device”等特殊状态单独标记，不强制填 0； 4. 统一字段数据类型。	Size 列混杂 19M、201k、Varies with device；Installs 带 10,000+。统一 M/k 换算为 MB，去除逗号加号，特殊文本做标记。

The Movies Dataset

问题类型	发现办法	处理办法	举例
1. 缺失值	用 df.isna().sum() 统计各列空值数量。检查特殊占位符（如 “未知”、“空字符串”）。	1. 不盲目全量填充，区分缺失原因。2. 缺失率低可删除，占比高用中位数 / 众数插补。3. 针对特定字段，空值可能代表特定含义，保留缺失标记。	runtime、release_date 等有缺失。系列信息为空可能代表该电影不属于任何系列，因此不统一填充。
2. 重复数据	用 df.duplicated().sum() 查完全重复行。用 value_counts() 检查唯一标识（id）。不能仅凭电影名判断重复，需联合多列核验。	1. 整行完全重复：保留第一条，删除其余重复样本。2. id 相同但属性不同：按 id 联合属性核验，不能仅凭同名判断重复，标记待人工复核。	数据集中存在重复电影条目。同名电影可能是翻拍或不同版本，需按 id 和属性核验，不自动删除。
3. 异常值 / 噪声（逻辑错误、错位）	业务值域校验：如 adult 字段应为布尔值（True/False），检测是否混入剧情文字。检查整体行是否 “错位”。	1. 确认是录入错位错误，无法修复的样本做隔离标记，不强行修改。2. 不直接全部删除，保留原始记录，记录处理日志。	adult 布尔字段混入剧情文字，显示整行错位。无法可靠还原时隔离，不做自动修正。
4. 类型 / 格式不一致	检查数据类型（dtypes）。查看文本字段是否包含多种单位、符号。检查日期格式是否统一。	1. 统一解析：从 budget 等字段中提取数值，去除文本。2. id 等字段检查是否出现日期格式，统一转换。3. 解析失败保留原值并标记。	id 出现 1997-08-20，budget 混入图片路径。检测解析失败并保留原值，不盲目统一修改。