# 选题一 | 这款 App 凭什么火？

## 应用商店数据质量智能体与应用画像聚类

**Agent 最终任务：**接收应用 CSV，识别四类质量问题，制定并执行清洗方案、复检；随后完成应用聚类，解释各群体特征并列出代表应用。

**数据内容：**Google Play Store Apps（lava18）；主表 googleplaystore.csv。原始版为 10,841 条记录、13 个字段；每行是一条应用信息记录，包含重复。

**下载：**https://www.kaggle.com/datasets/lava18/google-play-store-apps

**文件范围：**仅使用主表，不接入评论表。 备用：原始 CSV 镜像

### 1. 全部字段及含义

| 字段 | 含义 |
|---|---|
| App | 应用名称 |
| Category | 应用所属的商店类别 |
| Rating | 应用平均评分，满分 5 分 |
| Reviews | 用户评论数量 |
| Size | 安装包大小；可能带 M、k 等单位或特殊文本 |
| Installs | 安装量档位 / 下限，如 10,000+；不是精确下载次数 |
| Type | 免费或付费（Free / Paid） |
| Price | 应用价格（美元） |
| Content Rating | 内容适龄分级，如 Everyone、Teen |
| Genres | 应用细分类 / 风格标签，可含多个标签 |
| Last Updated | 采集时记录的最近更新日期 |
| Current Ver | 采集时记录的应用版本号 |
| Android Ver | 要求的最低 Android 版本，部分随设备变化 |

### 2. 是否满足项目要求

**结论：**规模超过 5,000 条、10 字段；四类问题有原生样例；下游采用聚类，无需预设标签。

| 问题类型 | 原始数据中的证据与拟处理方式 |
|---|---|
| 缺失值 | Rating 存在 NaN；区分缺失状态，再选择插补或保留缺失标记。 |
| 重复数据 | 存在整行完全重复；同名但属性不同的记录单独核验，不盲目合并。 |
| 异常 / 噪声 | 错位记录出现 Rating=19；结合相邻字段定位，无法可靠修复则隔离。 |
| 类型 / 格式不一致 | Size 混用 19M、201k、Varies with device；统一单位，特殊状态不填零。 |

### 3. 后续工作流与输出

导入并统计 → Agent 制定计划 → Python 工具清洗 → 复检与修正 → 特征处理 → K-means 聚类 → 输出应用画像。

初始特征选评分、安装量档位、评论数、价格、大小；长尾数值对数变换后缩放。类别用于解释群体；比较不同簇数的轮廓系数和多次运行稳定性，不预设群体结论。

**输出：**清洗后 CSV、质量问题与处理前后对照、应用分群与代表样本、可复现的工具调用日志。

**共同实现：**两题均由 LLM 决策与解释、Python 工具计算；不确定的修复交人工确认。记录模型、提示词、参数、调用次数 / 成本及错误修正。

**核查依据：**原始发布页 · 原始 CSV（字段、缺失、重复和错位样例）

# 选题二｜好片为何不一定热门？

## 电影数据质量智能体与口碑—热度聚类

**Agent 最终任务：**接收电影 CSV，识别缺失、重复、错位与格式问题，执行清洗并复检；按口碑和热度分群，解释群体差异并列出代表电影。

**数据内容：**The Movies Dataset（Rounak Banik）；主表 movies_metadata.csv。原始版为 45,466 条记录、24 个字段；每行是一条电影元数据记录，包含重复和异常。

**下载：**https://www.kaggle.com/datasets/rounakbanik/the-movies-dataset

**文件范围：**只用 movies_metadata.csv；不接入用户评分、演职员表，不做完整推荐系统。

### 1. 全部字段及含义

| 字段 | 含义 | 字段 | 含义 |
|---|---|---|---|
| adult | 成人内容标记 | production_companies | 制片公司列表 |
| belongs_to_collection | 所属电影系列信息 | production_countries | 制作国家列表 |
| budget | 制作预算（美元） | release_date | 上映日期 |
| genres | 电影类型列表 | revenue | 票房收入（美元） |
| homepage | 电影官网地址 | runtime | 片长（分钟） |
| id | TMDB 电影标识 | spoken_languages | 对白语言列表 |
| imdb_id | IMDb 电影标识 | status | 制作 / 发行状态 |
| original_language | 原始语言代码 | tagline | 电影宣传语 |
| original_title | 原始片名 | title | 展示片名 |
| overview | 剧情简介 | video | TMDB 视频布尔标记 |
| popularity | TMDB 综合热度分数 | vote_average | TMDB 平均评分（0–10） |
| poster_path | 海报相对路径 | vote_count | TMDB 评分人数 |

列表 / 系列信息在 CSV 中多为字符串化结构；video 不是视频下载链接。

### 2. 是否满足项目要求

**结论：**规模超过 5,000 条、10 字段；公开原始版与运行记录支持四类问题，可开展聚类。

| 问题类型 | 公开样例 / 记录与拟处理方式 |
|---|---|
| 缺失值 | runtime、release_date 等有缺失；系列为空可能不适用，不统一填充。 |
| 重复数据 | 存在重复电影条目；按 id 联合属性核验，不能仅凭同名判断重复。 |
| 异常 / 噪声 | adult 布尔字段混入剧情文字，显示整行错位；无法可靠还原时隔离。 |
| 类型 / 格式不一致 | id 出现 1997-08-20，budget 混入图片路径；检测解析失败并保留原值。 |

### 3. 后续工作流与输出

导入并统计 → Agent 定位重复与错位 → 解析类型列表并清洗 → 复检 → 构建评分、投票数、热度、片长、年份特征 → 缩放与聚类 → 输出电影群体。

使用 K-means，按轮廓系数与多次运行稳定性选择簇数；电影类型用于解释。“高分低热度”等仅为待探索方向，低投票数的高评分需单独提示。

**输出：**清洗后 CSV、问题与修正记录、电影分群、代表电影及口碑—热度对比。

数据为历史快照；以上依据公开资料与样例，未做本次全量审计，导入后须复核问题数量与保留规模。同一错位可触发多类问题；聚类只描述群体，不证明走红原因。

**核查依据：**原始发布页 · 作者字段与规模说明 · 错位样例 · 重复检查记录